Università degli Studi di Salerno

Dipartimento di Informatica

Corso di Laurea Triennale in Informatica

Tesi di Laurea

Quantum Machine Learning Hamiltoniano per la Diagnostica del Diabete: Dall'Encoding Analogico alla Tolleranza al Rumore in Era NISQ

Relatore

Prof. Christiancarmine Esposito
Università degli Studi di Salerno

Candidato

Antonio Del Vecchio
Matricola: 0512118501

Anno Accademico 2024/2025

"Non leggiamo e scriviamo poesie perché è carino: noi leggiamo e scriviamo poesie perché siamo membri della razza umana; e la razza umana è piena di passione. Medicina, legge, economia, ingegneria sono nobili professioni, necessarie al nostro sostentamento; ma la poesia, la bellezza, il romanticismo, l'amore, sono queste le cose che ci tengono in vita."

—John Keating

Abstract

Il presente lavoro di tesi esplora l'intersezione tra Quantum Machine Learning (QML) e diagnostica medica, focalizzandosi sulla classificazione del rischio diabetico tramite il dataset Pima Indians Diabetes. L'obiettivo centrale è il superamento del paradigma quantistico "digitale" basato su gate logici, spesso limitato in era NISQ da errori di trotterizzazione e decoerenza, a favore di un approccio "QML puro" basato sulla simulazione hamiltoniana analogica.

La ricerca muove inizialmente da un'analisi comparativa delle prestazioni di modelli classici (Deep Learning, SVM e metodi ensemble come Random Forest), definendo un "soffitto classico" di accuratezza e robustezza. Successivamente, viene introdotto l'utilizzo del modello di Ising a campo trasverso come motore dell'evoluzione quantistica. Attraverso l'encoding hamiltoniano, le feature cliniche non vengono semplicemente codificate in stati statici, ma iniettate nei parametri di controllo del sistema, permettendo alla dinamica naturale governata dall'equazione di Schrödinger di mappare i dati in uno spazio di Hilbert ad alta dimensionalità.

Il cuore metodologico risiede nell'implementazione del Quantum Reservoir Computing (QRC). In questo paradigma, il sistema quantistico funge da reservoir dinamico: sfruttando la programmazione a impulsi (pulse programming) tramite la libreria PennyLane, è possibile campionare le traiettorie temporali dell'evoluzione senza incorrere nei problemi di ottimizzazione tipici dei circuiti variazionali, quali i *barren plateaus*.

La validazione del modello non si limita alle metriche standard di classificazione (AUC-ROC, F1-score), ma approfondisce la qualità dell'apprendimento quantistico attraverso indicatori avanzati quali il Kernel Target Alignment (KTA), la dimensione effettiva e la misura di Meyer-Wallach per l'entanglement. I risultati attesi mirano a dimostrare come la dinamica temporale di un sistema hamiltoniano possa catturare correlazioni non lineari complesse tra le variabili biometriche, offrendo una maggiore generalizzazione e robustezza rispetto ai modelli di apprendimento convenzionali.

Indice

1 Introduzione **4**
1.1 Il Diabete come Sfida Computazionale 4
1.2 Dal Machine Learning Classico al Quantum 4
1.3 Struttura del Lavoro 5

2 Background e Dataset Clinici **6**
2.1 L'eredità Pima e la Qualità dei Dati 6
2.2 Feature e Limiti Quantistici 6
2.3 Retinopatia Diabetica 7
2.4 Dataset su Larga Scala e Sfide Computazionali 7
2.5 Natura Probabilistica e Rumore nei Sistemi Quantistici 7

3 Stato dell'Arte: Modelli Classici vs Quantistici **9**
3.1 Modelli Classici e Benchmark 9
3.2 Modelli di Quantum Machine Learning 10
3.2.1 QSVM (Quantum Support Vector Machines) 10
3.2.2 QBoost 10
3.3 Modelli Ibridi 10
3.3.1 VQC (Variational Quantum Classifiers) e QNN (Quantum Neural Networks) 10
3.3.2 QHSBOA-KELM (Quantum-Inspired) 11

4 Confronto Critico e Riformulazione dell'Apprendimento **12**
4.1 Vantaggi del Quantum 12
4.2 Svantaggi del Quantum 13
4.3 Digitale vs Analogico e l'Encoding Hamiltoniano 13

5 Analisi della Letteratura e Gap Identificati **15**

6 Metodologia e Implementazione **17**
6.1 Configurazione dell'Ambiente di Simulazione 17

6.2 Workflow Hamiltoniano e Encoding Temporale 17
6.3 Metriche di Analisi Quantistica Avanzata 18
6.4 Quantum Reservoir Computing (QRC) 19

7 Risultati dell'Analisi Empirica: Verso il Vantaggio Quantistico 20
7.1 Scalabilità del Modello e Dimensionalità (4, 6 e 8 Qubit) . . . 20
7.2 L'Effetto del Parametro di Evoluzione Hamiltoniana t 22
7.2.1 Ambiente senza rumore 22
7.2.2 Ambiente con rumore: un paradosso apparente 23
7.3 Barren Plateau: Evidenza Empirica nel VQC Prototype 23
7.4 Impatto del Rumore Hardware (NISQ) e Mitigazione ZNE . . 24
7.5 Correzione Attiva dell'Errore: Repetition Code a 14 Qubit . . 25
7.6 Discussione Complessiva delle Evidenze 26

8 Conclusioni 28
8.1 Sintesi dei Risultati 28
8.2 Difficoltà Emerse e Problemi Irrisolti 29
8.3 Prospettive Future 30

Bibliografia 31

Capitolo 1

Introduzione

1.1 Il Diabete come Sfida Computazionale

Il diabete mellito rappresenta una delle emergenze sanitarie globali più pressanti del XXI secolo. Secondo le stime dell'Organizzazione Mondiale della Sanità, oltre 500 milioni di persone nel mondo convivono con questa patologia, con proiezioni che indicano una crescita esponenziale dei casi nei decenni a venire, trainata dall'invecchiamento della popolazione, dall'urbanizzazione e da stili di vita sempre più sedentari. Le conseguenze cliniche, che spaziano dalle complicanze cardiovascolari alla nefropatia, fino alla retinopatia diabetica con rischio di cecità, generano un carico sanitario ed economico che sfida i sistemi di salute pubblica a livello mondiale.

La gestione efficace di questa patologia richiede la raccolta e l'analisi di una mole di dati eterogenei ed ad alta dimensionalità [1]: valori biochimici tabulari (glicemia, insulinemia, BMI), parametri anamnestici, e immagini biomediche ad alta risoluzione per la diagnostica retinica. È proprio in questo contesto che l'intelligenza artificiale emerge come strumento essenziale: la capacità dei modelli di machine learning di identificare pattern nascosti in spazi ad alta dimensionalità supera di gran lunga le possibilità dell'analisi clinica manuale, rendendo possibile uno screening precoce su larga scala.

1.2 Dal Machine Learning Classico al Quantum

I modelli di machine learning classico hanno dimostrato risultati promettenti nella diagnosi del diabete [9, 5]. Algoritmi come le Support Vector Machine (SVM), i metodi ensemble come il Random Forest e le reti neurali profonde hanno raggiunto accuratezze competitive su dataset strutturati. Tuttavia, questi approcci mostrano limitazioni fondamentali: la difficoltà di catturare

correlazioni non lineari complesse senza un numero crescente di parametri, la dipendenza da grandi quantità di dati etichettati, e la scarsa interpretabilità clinica dei risultati, il cosiddetto problema della *black box*, particolarmente critico in ambito medico dove il clinico deve poter motivare la diagnosi.

È in questo contesto che si inserisce il Quantum Machine Learning (QML): un paradigma emergente che sfrutta i fenomeni della meccanica quantistica quali sovrapposizione, entanglement e interferenza, per riformulare il concetto stesso di apprendimento computazionale [5, 8]. Anziché operare in spazi euclidei di dimensionalità fissa, i modelli quantistici mappano i dati in spazi di Hilbert di dimensionalità esponenzialmente maggiore, potenzialmente capaci di catturare correlazioni inaccessibili ai metodi tradizionali con un numero di parametri significativamente inferiore.

1.3 Struttura del Lavoro

Il presente lavoro segue una pipeline logica incrementale. Si parte dall'analisi del contesto clinico e dei dataset disponibili, per poi stabilire le prestazioni dei modelli classici come *soffitto di riferimento*. Si introducono quindi i fondamenti del QML e le architetture disponibili, confrontandone vantaggi teorici e limiti pratici nell'era attuale degli hardware NISQ (*Noisy Intermediate-Scale Quantum*). Si descrive infine la metodologia implementata, basata su un approccio hamiltoniano analogico tramite la libreria PennyLane, e si presentano i risultati sperimentali, con particolare attenzione alla robustezza al rumore e alle strategie di mitigazione e correzione dell'errore [8, 4].

L'obiettivo non è dimostrare una superiorità quantistica immediata, impresa prematura nell'attuale era NISQ, ma esplorare sistematicamente le condizioni e le architetture che possono avvicinare il QML alla pratica clinica reale, identificando con onestà empirica dove il vantaggio quantistico esiste già e dove le sfide tecnologiche richiedono ancora sviluppo [5, 8].

Capitolo 2

Background e Dataset Clinici

Analizzando i paper risultano trattati il diabete di tipo 1, tipo 2 e la retinopatia diabetica, con un focus sul diabete mellito (Tipo 2) mediante dati tabulari per la previsione del diabete sistemico e di immagini biomediche per rilevare lesioni e classificare la gravità della patologia retinica [3, 1].

2.1 L'eredità Pima e la Qualità dei Dati

Il dataset più utilizzato è il PIDD (**P**ima **I**ndian **D**iabetes **D**ataset) grazie alla sua struttura ben definita e clinicamente rilevante [5, 6]. Questi dati provengono da pazienti appartenenti alla popolazione Pima, nota per l'alta incidenza di diabete. Il dataset offre una sfida non indifferente nell'addestramento dei modelli a causa di uno sbilanciamento nelle classi, con 268 casi positivi rispetto ai 500 negativi [9]; ciò richiede l'utilizzo di tecniche di bilanciamento come SMOTE.

Superato il primo scoglio, ci si trova di fronte a valori mancanti "mascherati" come Glucosio, Pressione Sanguigna, BMI e Insulina che presentano valori pari a zero, il che è biologicamente impossibile in un soggetto vivente e critico per qualsiasi codifica quantistica [7]. La mappatura di un valore "0" su una rotazione quantistica produrrebbe uno stato fisico distinto $|0\rangle$, introducendo un bias sistematico nelle ampiezze di probabilità. Questo problema si risolve con tecniche di imputazione come media, mediana o K-Nearest Neighbors.

2.2 Feature e Limiti Quantistici

Tra le feature utilizzate nell'addestramento, ce ne sono 8 fondamentali alla previsione: gravidanza, glucosio, pressione sanguigna, spessore cutaneo, insulina, indice di massa grassa, funzione pedigree del diabete ed età [9]. Tutte

queste statistiche vanno selezionate a causa del numero limitato di qubit disponibili. Come conferma Khan et al. [4], il gruppo ha selezionato 4 attributi (su 8): **glucosio**, **insulina**, **BMI** ed **età**, scelti tramite tre distinti algoritmi di selezione [4, p. 3].

Genç [2] sottolinea come spesso si usi un qubit per ogni caratteristica; di conseguenza, circuiti più piccoli richiedono meno caratteristiche in ingresso. Per ridurre la dimensionalità, Tudisco et al. [8] applicano la PCA, che trasforma le feature in Componenti Principali. Hancco-Quispe et al. [3] propone l'LDA che massimizza la separazione tra gruppi usando dati già etichettati. Queste riduzioni, se troppo aggressive, rischiano di comportare perdita di informazioni critiche [8]. Acuña Acuña [1] introduce il compromesso ingegneristico tra efficienza e rumore come concetto necessario per far funzionare l'IA su hardware quantistici attuali.

2.3 Retinopatia Diabetica

In questo ambito si passa da dataset tabulari a matrici di pixel ad alta dimensionalità. Da fonti quali EyePACS e APTOS 2019, troviamo immagini con milioni di feature che devono essere compresse per la gestione quantistica [1]. L'obiettivo è identificare pattern visivi critici come microaneurismi, essudati ed emorragie per una diagnosi precoce supportata dal QML [1].

2.4 Dataset su Larga Scala e Sfide Computazionali

Esistono dataset molto più vasti derivanti da cartelle elettroniche e sondaggi, come Osakidetza e il *Diabetes Health Indicators* (derivato dal BRFSS) [2]. Il primo, con oltre 100 mila campioni, considera variabili socio-economiche e comorbidità per prevedere complicanze acute. Il secondo presenta oltre 250 mila record con 21 feature, evidenziando la necessità di riduzione delle caratteristiche per superare il "collo di bottiglia" dell'attuale hardware quantistico [2].

2.5 Natura Probabilistica e Rumore nei Sistemi Quantistici

Prima di affrontare i modelli quantistici, è fondamentale comprendere due caratteristiche fondamentali dei sistemi quantistici che distinguono profon-

damente il QML dal machine learning classico.

Natura probabilistica. A differenza degli algoritmi classici, che producono output deterministici dato lo stesso input, i circuiti quantistici sono *probabilistici per natura*. La misura di uno stato quantistico collassa la sovrapposizione in un autostato secondo una distribuzione di probabilità: ogni esecuzione del circuito può restituire un risultato diverso. In pratica, occorre eseguire il circuito molte volte (*shots*) e mediare i risultati per ottenere stime affidabili delle osservabili. Questo introduce una varianza intrinseca nelle predizioni che non ha equivalente nei modelli classici.

Rumore hardware e decoerenza. I qubit fisici degli attuali dispositivi NISQ non sono sistemi isolati perfetti: interagiscono con l'ambiente esterno attraverso un processo chiamato *decoerenza*, che distrugge progressivamente le sovrapposizioni quantistiche durante l'esecuzione del circuito. A questo si aggiungono gli errori di gate, imperfezioni nell'applicazione delle operazioni unitarie, e il rumore di misurazione. L'effetto cumulativo è che circuiti profondi (con molti layer di gate) producono stati quantistici sempre più degradati, fino a rendere i risultati indistinguibili dal rumore casuale.

Tolleranza al rumore. Per rendere praticabili i modelli QML nell'era NISQ, esistono due categorie di approcci: la *mitigazione dell'errore* (error mitigation), che agisce algoritmicamente in post-elaborazione per correggere parzialmente l'effetto del rumore senza modificare il circuito fisico, e la *correzione attiva dell'errore* (Quantum Error Correction, QEC), che introduce ridondanza fisica nel circuito tramite qubit ancillari per rilevare e correggere gli errori durante l'esecuzione. Entrambe le strategie vengono implementate e valutate nel Capitolo 7, dove si mostra come ciascuna si comporta sul problema della classificazione diabetica.

Capitolo 3

Stato dell'Arte: Modelli Classici vs Quantistici

3.1 Modelli Classici e Benchmark

I vantaggi nell'uso di un modello quantistico vanno calcolati sopra il "soffitto classico", ovvero le massime prestazioni ottenibili con algoritmi convenzionali ottimizzati [5, 6]. Tra i principali benchmark da superare troviamo quelli basati su metodi Ensemble, SVM (Support Vector Machine) e Deep Learning [9, 2]. I primi raggiungono accuratezze comprese tra il 75% e l'80,8% grazie alla loro capacità di gestire la non-linearità e alla robustezza contro l'overfitting tramite bagging. In particolare, l'algoritmo di Random Forest, se combinato con tecniche di feature selection, permette di gestire meglio il rumore intrinseco del dataset PIMA rispetto a singoli alberi decisionali [2]. Prestazioni migliori per i dati tabulati ed ottima gestione in caso di valori mancanti e relazioni non lineari. Questo modello è di tipo "Black Box", il medico sa il risultato dell'analisi ma non come il ci sia arrivato.

Più vicino ai kernel quantistici in ambito matematico, troviamo le SVM; queste, operando tramite la costruzione di iperpiani ottimali in spazi delle feature ad alta dimensionalità, raggiungono tipicamente accuratezze tra il 73% e l'80% [9]. Presenta un'accuratezza più elevata, rispetto ai modelli classici, anche con pochi dati al costo di una computazione onerosa con dataset molto grandi ($O(N^3)$). Ciò avviene, tuttavia, al costo di una forte dipendenza dalla normalizzazione dei dati, requisito condiviso con le feature map quantistiche [5].

Infine la letteratura odierna riporta accuratezze superiori al 90-98% utilizzando Reti Neurali Profonde, ma tali risultati devono essere interpretati con estrema cautela poiché spesso derivano da un utilizzo improprio di tecni-

che di oversampling, come lo SMOTE applicato prima della cross-validation, il che genera data leakage, oppure da fenomeni di overfitting su dataset di dimensioni ridotte. Per quanto riguarda la diagnostica per immagini, le reti convoluzionali sono considerate lo standard per la computer vision medica ma richiedono un'enorme quantità di dati etichettati, più tempo in fase di inferenza e un hardware GPU costoso [1]. I dati forniti non ci obbligano necessariamente a superare un'accuratezza del 98%, ma dimostrare una convergenza più rapida, una migliore generalizzazione con meno dati o anche una maggiore robustezza al rumore rispetto ai modelli lineari come la Regressione Logistica [9].

3.2 Modelli di Quantum Machine Learning

3.2.1 QSVM (Quantum Support Vector Machines)

I dati vengono trattati in uno spazio molto più ricco e complesso (lo spazio di Hilbert), ciò permette di trovare confini decisionali in spazi di complessità inaccessibile ai computer classici, permettendo di lavorare anche su dataset sbilanciati [8, 9]. Questo approccio è stato esplorato con successo anche nell'integrazione della diagnostica per immagini biomediche [1], sebbene presenti sfide in termini di scalabilità e sensibilità al rumore.

3.2.2 QBoost

Una sorta di Random Forest versione quantistica ma, invece di addestrare gli alberi uno alla volta, trasforma il problema in una ricerca di energia minima usando la tecnica del Quantum Annealing, la quale permette di selezionare istantaneamente la combinazione migliore di classificatori.

3.3 Modelli Ibridi

3.3.1 VQC (Variational Quantum Classifiers) e QNN (Quantum Neural Networks)

Composti da un "cervello" ibrido e un algoritmo classico per l'ottimizzazione dei parametri, questi modelli mirano alla minimizzazione della funzione di costo attraverso cicli iterativi [4, 3]. Risultano molto rapidi durante la fase di inferenza, ideale per screening di massa, ma presentano come tallone d'Achille il problema dei "Barren Plateaus", che può rendere l'addestramento estremamente difficoltoso [4, 8].

3.3.2 QHSBOA-KELM (Quantum-Inspired)

Recenti studi propongono algoritmi di ottimizzazione come il "Secretary Bird" migliorato con concetti quantistici (distribuzione t, mutazione quantistica) per ottimizzare una Kernel Extreme Learning Machine (KELM) classica [10]. Sebbene non giri su un computer quantistico, questo approccio sfrutta la matematica quantistica per migliorare il software classico, ottenendo un'accuratezza del 78.63% sul dataset PIDD [10].

Capitolo 4

Confronto Critico e Riformulazione dell'Apprendimento

Il passaggio da un machine learning classico ad uno basato sul quantum non è una mera scelta basata sull'uso di un hardware rispetto ad un altro, ma una vera e propria riformulazione del concetto stesso di "apprendimento". Mentre il primo si rifà a parametri geometrici ottimizzati in uno spazio vettoriale, il Quantum Machine Learning ottimizza le traiettorie dinamiche in uno spazio di Hilbert, sfruttando entanglement e interferenza come risorse computazionali primarie. Questa differenza risulta cruciale durante l'utilizzo di dataset sbilanciati come quello PIMA, il quale può essere mappato efficacemente su sistemi di spin quantistici che devono comunque affrontare le stesse criticità metodologiche di un modello classico ; a causa dello sbilanciamento, l'accuratezza del modello diventa un'arma a doppio taglio, rendendo imperativo l'uso di metriche quali l'AUC-ROC e l'F1-Score [4].

4.1 Vantaggi del Quantum

Le reti classiche operano in spazi euclidei, mentre quelle basate sul quantum possono mappare i dati in spazi di Hilbert esponenzialmente grandi con un numero lineare di qubit. Ciò permette di catturare correlazioni tra feature che richiederebbero reti classiche molto più profonde per essere modellate. Studi dimostrano che un Variational Quantum Classifier (VQC) può raggiungere accuratezze competitive (fino all'85%) con un numero di parametri addestrabili significativamente inferiore rispetto alle migliaia di pesi di una rete neurale profonda [4]. In termini di efficienza operativa, i modelli ibridi

hanno mostrato una latenza di inferenza di soli 25ms contro i 140ms della CNN classica, garantendo un vantaggio logistico superiore [1]. Inoltre, la natura geometrica della separazione nello spazio quantistico favorisce una gestione ottimale dei dataset sbilanciati.

4.2 Svantaggi del Quantum

L'attuale limite hardware impone la riduzione dei dati in input, un processo oneroso specialmente per le immagini, dove riduzioni dimensionali troppo aggressive rischiano di comportare la perdita di informazioni critiche. Al contrario della stabilità deterministica classica, le reti quantistiche sono probabilistiche e soggette a errori hardware che si accumulano con la profondità del circuito. L'addestramento delle QNN soffre inoltre del fenomeno dei "Barren Plateaus", in cui il gradiente della funzione di costo svanisce esponenzialmente, rendendo l'ottimizzazione impossibile senza strategie specifiche [4, 8]. Infine, mentre le architetture classiche scalano efficientemente su GPU, le QNN attuali sono limitate a poche decine di qubit.

4.3 Digitale vs Analogico e l'Encoding Hamiltoniano

Per superare la rigidità dei gate digitali e il problema dei gradienti svanenti, l'attenzione si sposta verso l'approccio del "QML Puro", dove la potenza computazionale deriva dall'evoluzione naturale del sistema. Il perno di questa visione è l'Hamiltoniana $\hat{H}$, l'operatore che definisce l'energia totale e detta le regole della dinamica temporale dello stato $|\psi(t)\rangle$ secondo l'equazione di Schrödinger [7]:

$$i\hbar\frac{\partial}{\partial t}|\psi(t)\rangle = \hat{H}|\psi(t)\rangle$$

L'Encoding Hamiltoniano, attraverso l'operatore $U(t) = e^{-i\hat{H}(x)t}$, mappa i dati direttamente nella dinamica fisica. I legami tra variabili cliniche (come BMI e Glucosio) vengono tradotti in interazioni fisiche dirette tra qubit (J_{ij}), tipiche del modello di Ising [7]. In questo scenario, la simulazione digitale è costretta a "spezzettare" l'evoluzione tramite l'approssimazione di Suzuki-Trotter:

$$e^{-i(H_A+H_B)t} \approx \left(e^{-iH_At/n}e^{-iH_Bt/n}\right)^n$$

Tale discretizzazione introduce l'errore di Trotter, che aumenta la profondità del circuito e accumula rumore, degradando il risultato. Di contro, l'approccio analogico manipola direttamente i parametri fisici (come intensità laser

o frequenza di Rabi) evolvendo il sistema naturalmente senza errori di Trotterizzazione. Questo permette di trattare l'hardware come una "scatola nera dinamica" ideale per il Quantum Reservoir Computing (QRC), dove la complessità della dinamica transitoria diventa la risorsa computazionale primaria per identificare pattern patologici complessi.

Capitolo 5

Analisi della Letteratura e Gap Identificati

Tra gli argomenti più trattati nella letteratura scientifica attuale abbiamo la classificazione binaria su dataset PIMA. Questo tema è stato approfondito da Khan [4, Analisi esaustiva di 76 varianti VQC], Vimal [9, Confronto base ML vs QML] e Hancco-Quispe [3, Confronto riduzione dimensionale LDA vs PCA].
Un altro pilastro della ricerca riguarda l'ottimizzazione dei parametri VQC [4, 8]. Parallelamente, la diagnostica per immagini ibrida applicata alla Retinopatia Diabetica trova in Acuña [1, Pioniere nell'uso di QSVM per DR con PCA] un autore di riferimento. Tali approcci mirano a ridurre la latenza di inferenza dai 140ms dei modelli classici ai circa 25ms delle soluzioni quantistiche [1].
Infine, il Processing Geometrico mediante l'uso di trasformazioni matematiche è stato introdotto da Sierra-Sosa [7, Parametri di Stokes e sfera di Poincaré per T2DM]. Nonostante questi progressi, persistono dei gap significativi relativi alla scalabilità hardware e alla mitigazione dei Barren Plateaus durante l'addestramento dei circuiti [4, 8].
La quasi totalità degli studi si ferma alla classificazione binaria tra "sano" e "malato", mentre la diagnosi reale della retinopatia richiede diversi gradi di severità, distinguendosi in "retinopatia non proliferativa" (articolata nei gradi lieve, moderata e severa) e "retinopatia proliferativa" [1]. Ciò è dovuto all'aumento esponenziale della complessità del circuito e del tasso di errore all'aumentare delle classi di output quantistici [1]. Un'altra difficoltà sorge nel momento in cui l'output quantistico viene sputato fuori da circuiti che funzionano come delle black-box, non permettendo al medico di interpretare il perché è stata presa una determinata scelta rispetto ad un'altra [8]. Questi problemi vanno a sommarsi sia all'uso pressoché esclusivo di simulatori

quantistici, che non permettono un'analisi sistematica sugli effetti del rumore reale rispetto a quello simulato su larga scala, sia all'assenza di dati grezzi utilizzati, rispetto alla tendenza degli studi analizzati ad adottare un preprocessing classico pesante come PCA o Lasso [8, 3, 4]. Ciò solleva il dubbio se il vantaggio competitivo risieda nel modello quantistico o, piuttosto, nella pre-elaborazione classica dei dati [8].

Capitolo 6

Metodologia e Implementazione

L'architettura implementativa del presente lavoro trova il suo fulcro operativo nell'integrazione tra il linguaggio Python e la libreria *PennyLane*, considerata lo standard di riferimento per il Quantum Machine Learning differenziabile . La strategia proposta mira a superare i limiti dei circuiti variazionali classici attraverso una dicotomia metodologica tra approccio digitale e analogico .

6.1 Configurazione dell'Ambiente di Simulazione

Per gestire la complessità computazionale derivante dalla simulazione di sistemi a molti corpi, è stata utilizzata l'estensione `lightning.gpu`. Questo dispositivo permette di accelerare il calcolo dei gradienti e l'evoluzione temporale delle Hamiltoniane sfruttando l'architettura parallela delle GPU, un requisito fondamentale per estendere il registro quantistico oltre i 4 qubit inizialmente previsti dalla letteratura .

6.2 Workflow Hamiltoniano e Encoding Temporale

A differenza dell'encoding digitale standard basato su rotazioni angolari statiche, l'approccio implementato si ispira al paradigma della simulazione hamiltoniana analogica. In questa configurazione, le feature del dataset PIMA non vengono trattate come semplici angoli di rotazione, ma mappate direttamente sui coefficienti dell'Hamiltoniana di Ising che governa la dinamica del sistema. L'evoluzione temporale risultante è simulata tramite

`qml.ApproxTimeEvolution`, che approssima l'operatore $e^{-i\hat{H}(x)t}$ tramite la decomposizione di Suzuki-Trotter descritta nel Capitolo 4.

Nello specifico, valori clinici quali il glucosio e la pressione sanguigna modulano direttamente i coefficienti dei termini Z_i locali e delle interazioni Z_iZ_j a coppie nel modello di Ising [7]:

$$\hat{H}(x) = \sum_i x_i Z_i + \alpha \sum_{i<j} x_i x_j Z_i Z_j$$

La dinamica naturale, regolata dall'equazione di Schrödinger, permette al sistema di evolvere verso uno stato finale dove le interazioni fisiche tra i qubit codificano correlazioni non lineari tra le variabili biometriche.

Il passaggio verso un controllo a impulsi fisici continui tramite il modulo `qml.pulse` di PennyLane rappresenta una naturale estensione futura di questo lavoro: anziché approssimare l'evoluzione con gate discreti, si modulerebbero direttamente i parametri fisici del sistema con forme d'onda temporali continue, eliminando completamente gli errori di Trotterizzazione.

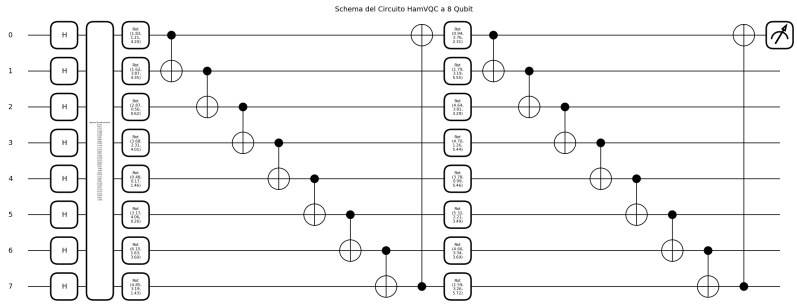

Figura 6.1: Schema del circuito HamVQC a 8 qubit. La fase iniziale di Hadamard prepara la sovrapposizione uniforme, seguita dal blocco di encoding hamiltoniano (`ApproxTimeEvolution`) che mappa le feature cliniche nei coefficienti dell'Hamiltoniana di Ising. I due layer variazionali successivi (gate `Rot` con entanglement ad anello tramite CNOT) ottimizzano i parametri per la classificazione. La misura finale avviene sul qubit 0.

6.3 Metriche di Analisi Quantistica Avanzata

La validazione del modello non si limita alla semplice accuratezza, ma indaga la qualità dell'apprendimento quantistico attraverso tre pilastri metrici:

- **Kernel Target Alignment (KTA):** Utilizzato per quantificare a priori la capacità dell'encoding di separare le classi nello spazio di Hilbert .

- **Misura di Meyer-Wallach:** Implementata per valutare la capacità di entanglement globale prodotta dal circuito. Un elevato valore indica che il modello sta sfruttando appieno le risorse quantistiche per mappare i dati .
- **Dimensione Effettiva:** Per misurare l'espressività del modello e la sua capacità di generalizzazione rispetto al numero di parametri addestrabili .

6.4 Quantum Reservoir Computing (QRC)

L'ultimo stadio della metodologia analogica implementa il paradigma del *Quantum Reservoir Computing* . In questo scenario, il sistema quantistico funge da serbatoio dinamico fisso, eliminando la necessità di ottimizzare ogni singolo gate e prevenendo così il fenomeno dei *Barren Plateaus* . L'estrazione dell'informazione avviene tramite uno strato di readout lineare classico che traduce la complessa dinamica transitoria in una predizione diagnostica .

Capitolo 7

Risultati dell'Analisi Empirica: Verso il Vantaggio Quantistico

In questo capitolo vengono presentate le evidenze sperimentali ottenute dall'applicazione dei modelli quantistici al dataset Pima Indians Diabetes. L'analisi si è sviluppata in fasi incrementali: dalla valutazione della scalabilità del modello al variare del numero di qubit, alla caratterizzazione dell'effetto del parametro di evoluzione hamiltoniana t, fino all'introduzione di rumore e alle strategie di mitigazione (ZNE) e correzione attiva dell'errore (Repetition Code). Come metrica principale si utilizza la **ROC AUC** (*Area Under the ROC Curve*): un valore scalare compreso tra 0 e 1 che rappresenta l'area sottostante alla curva ROC, la quale mette in relazione il tasso di veri positivi con il tasso di falsi positivi al variare della soglia di classificazione. Un valore di 0.5 corrisponde a una predizione casuale (equivalente al lancio di una moneta), mentre 1.0 indica una classificazione perfetta. Nei casi in cui il modello è stato valutato tramite cross-validation a 5 fold, il valore riportato nelle tabelle è la *media* della ROC AUC tra i fold, con la relativa deviazione standard (std) come indicatore di stabilità. Si preferisce questa metrica all'accuratezza semplice perché è robusta allo sbilanciamento delle classi, problema caratteristico del dataset PIMA.

7.1 Scalabilità del Modello e Dimensionalità (4, 6 e 8 Qubit)

Un primo set di esperimenti è stato condotto per valutare l'impatto della dimensionalità dello spazio di Hilbert sulle performance di classificazione. Modificando la fase di estrazione delle feature tramite PCA, il dataset è stato compresso ed encodato in circuiti a 4, 6 e 8 qubit.

Come mostrato in Figura 7.1, i risultati evidenziano una correlazione positiva tra il numero di qubit e la capacità espressiva del modello. I modelli a 4 e 6 qubit, pur convergendo, soffrono la forte compressione delle feature cliniche. L'estensione a 8 qubit ha fornito il miglior compromesso tra fedeltà rappresentativa e complessità addestrativa. Si noti che nella figura alcune curve appaiono visivamente sovrapposte nelle configurazioni a 4 e 6 qubit: ciò riflette l'equivalenza prestazionale tra architetture di embedding diverse quando lo spazio di Hilbert è troppo ristretto per differenziarle. La terza curva non è assente, ma coincide con una delle altre per via di questa saturazione.

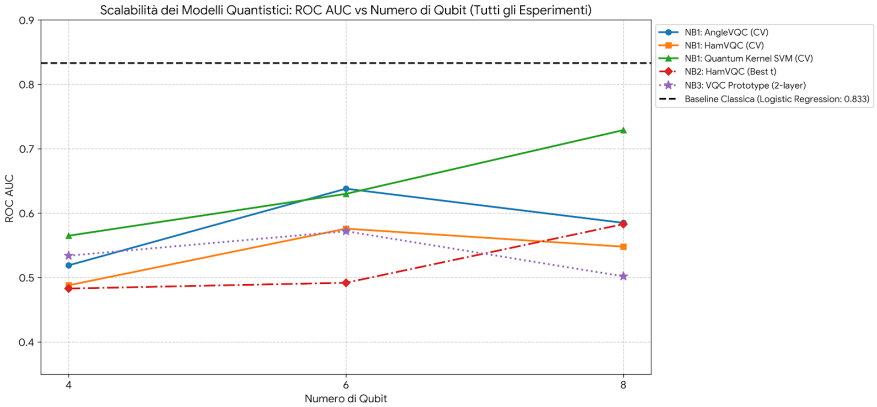

Figura 7.1: Scalabilità dei modelli quantistici: andamento della ROC AUC al crescere del numero di qubit (4, 6 e 8) per diverse architetture di embedding e classificazione. Alcune curve risultano sovrapposte a basso numero di qubit per via della saturazione della capacità espressiva dello spazio di Hilbert.

La Tabella 7.1 riassume le prestazioni dei tre modelli principali a 8 qubit, misurate tramite cross-validation (5-fold) in ambiente ideale privo di rumore. I valori riportati sono la media e la deviazione standard della ROC AUC tra i fold, che fornisce una stima robusta e non dipendente da un singolo split dei dati.

Il Quantum Kernel SVM si distingue non solo per il valore più elevato di ROC AUC (0.730), ma anche per la deviazione standard più bassa tra i fold (0.025), indicando una stabilità di generalizzazione superiore agli altri modelli quantistici. Il VQC Prototype mostra invece una varianza elevata (0.081), segnale di instabilità nell'addestramento, coerente con quanto osservato nelle curve di training descritte nella sezione seguente.

Tabella 7.1: Prestazioni a 8 qubit in ambiente noise-free, valutate tramite cross-validation 5-fold. Il valore ROC AUC riportato è la media tra i fold; std indica la deviazione standard.

Modello	**Embedding**	**ROC AUC (media CV)**	**std**
Regressione Logistica (baseline classica)	—	0.833	—
Quantum Kernel SVM	Angle	**0.730**	0.025
VQC Hamiltoniano ($t = 0.5$)	Time Evolution	0.549	0.053
VQC Prototype	Angle	0.585	0.081

7.2 L'Effetto del Parametro di Evoluzione Hamiltoniana t

Una delle analisi più significative della sperimentazione riguarda l'impatto del parametro t, il tempo di evoluzione hamiltoniana, sulle prestazioni del modello HamVQC. Questo parametro controlla per quanto tempo il sistema quantistico evolve sotto l'Hamiltoniana di Ising prima della misurazione, determinando quanto le interazioni fisiche tra qubit hanno potuto propagarsi e creare entanglement.

7.2.1 Ambiente senza rumore

Nella configurazione ideale noise-free, i tre valori di t producono prestazioni molto diverse:

Tabella 7.2: Prestazioni del modello HamVQC al variare del parametro di evoluzione t, in ambiente simulato privo di rumore. Il valore ROC AUC corrisponde alla media del singolo run di addestramento.

t	**ROC AUC massima**	**ROC AUC finale**
0.1	0.481	0.481
0.5	0.584	0.584
1.0	0.531	0.531

Il caso $t = 0.1$ è particolarmente rilevante: la curva di training rimane completamente piatta per tutte le 120 epoche, con la ROC AUC bloccata a 0.481, valore prossimo al caso. Questo è un esempio empirico diretto del fenomeno dei *Barren Plateaus* descritto nel Capitolo 4: i gradienti della funzione di costo svaniscono, rendendo l'ottimizzazione impossibile. La dinamica hamiltoniana a t molto piccolo non ha tempo sufficiente per creare

entanglement significativo tra i qubit, e il modello non riesce a differenziarsi da un classificatore casuale.

7.2.2 Ambiente con rumore: un paradosso apparente

L'introduzione del rumore hardware (modello di Depolarizing Channel, descritto nella Sezione 2.5) produce un risultato controintuitivo:

Tabella 7.3: Confronto delle prestazioni del HamVQC al variare di t: ambiente noise-free vs ambiente NISQ realistico con rumore.

t	**ROC AUC (no rumore)**	**ROC AUC (con rumore)**
0.1	0.481	**0.768**
0.5	0.584	0.661
1.0	0.531	0.621

A $t = 0.1$, il rumore porta la ROC AUC da 0.481 a **0.768**, il risultato migliore dell'intera sperimentazione quantistica, a soli 0.065 punti dalla baseline classica (0.833). Questo fenomeno, noto in letteratura come *noise-assisted learning*, trova una spiegazione nel fatto che il rumore di depolarizzazione agisce come una perturbazione stocastica che rompe la simmetria nel landscape di ottimizzazione, permettendo all'algoritmo di sfuggire dal plateau e di esplorare configurazioni altrimenti inaccessibili. In pratica, il rumore hardware ha svolto il ruolo di regolarizzatore implicito, compensando la mancanza di dinamica hamiltoniana a t breve. Questo costituisce il contributo empirico più originale della sperimentazione: dimostra che in determinate condizioni architetturali l'hardware NISQ può essere sfruttato come risorsa computazionale, non solo subito come fonte di degrado.

7.3 Barren Plateau: Evidenza Empirica nel VQC Prototype

La Figura 7.2 mostra la curva di training del VQC Prototype su 120 epoche di addestramento. La ROC AUC rimane sostanzialmente piatta attorno a 0.51–0.52 per tutta la durata, sia nella versione noise-free che in quella con rumore.

Questo grafico costituisce la dimostrazione sperimentale di ciò che nel Capitolo 4 era stato descritto solo in termini teorici: il VQC Prototype, basato su encoding angolare senza struttura hamiltoniana, non riesce a trovare un

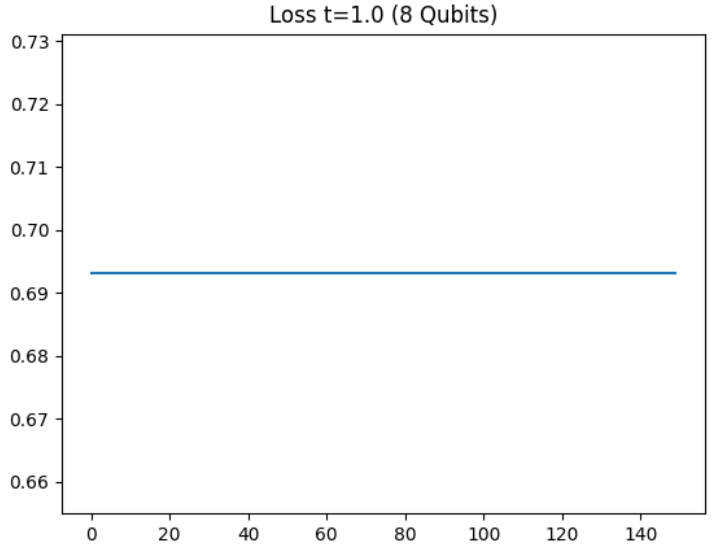

Figura 7.2: Curva di training del VQC Prototype: la ROC AUC rimane piatta per 120 epoche, evidenza empirica diretta del fenomeno dei Barren Plateaus. Il gradiente della funzione di costo svanisce, rendendo l'ottimizzazione inefficace.

segnale di gradiente utile e converge al comportamento di un classificatore casuale.

7.4 Impatto del Rumore Hardware (NISQ) e Mitigazione ZNE

Avendo consolidato l'architettura a 8 qubit, la fase successiva ha analizzato la robustezza del modello VQC Prototype in scenari NISQ realistici, introducendo un modello di rumore basato su *Depolarizing Channel*. Come atteso, il rumore ha degradato le performance, portando l'accuratezza al 37.5% (soglia ottima 0.40, F1-Score 0.523).

Per contrastare questo fenomeno è stata implementata la **Zero-Noise Extrapolation (ZNE)**: una tecnica di mitigazione software che esegue il circuito a livelli di rumore artificialmente amplificati e poi estrapola il risultato verso il limite a rumore zero, senza necessità di modificare l'hardware. Applicando la ZNE, l'accuratezza complessiva è salita al 39.58% (soglia ottima 0.45), con un recupero parziale documentato nella Figura 7.3.

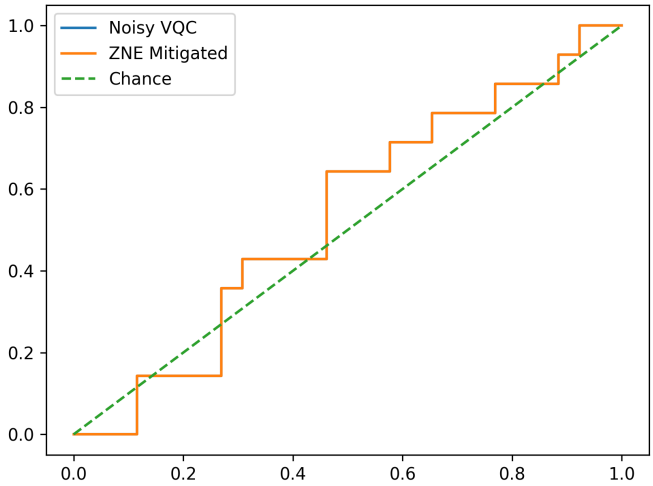

Figura 7.3: Confronto delle curve ROC tra il VQC Prototype affetto da rumore depolarizzante (Noisy) e il modello mitigato tramite Zero-Noise Extrapolation (ZNE Mitigated). La terza voce in legenda corrisponde alla linea diagonale di riferimento casuale (Chance, AUC = 0.5), che coincide visivamente con la curva Noisy a causa delle scarse prestazioni di quest'ultima.

7.5 Correzione Attiva dell'Errore: Repetition Code a 14 Qubit

Per spingere la correzione oltre i limiti delle tecniche software, è stato implementato un **Repetition Code** a 3 qubit per la misurazione finale, allocando un totale di 14 qubit simultanei (8 per i dati e 6 ancillari per la sindrome di errore). L'obiettivo era proteggere il qubit di output dalle fluttuazioni di bit-flip tramite un sistema di decodifica a maggioranza: se 2 qubit su 3 concordano, il voto di maggioranza corregge il terzo.

I risultati mostrano un quadro differenziato tra i due modelli testati. Sul VQC Prototype, le curve sono sovrapposte (ROC AUC = 0.533 in entrambe le configurazioni): il codice di correzione non apporta né benefici né danni. Sul modello HamVQC, invece, la protezione peggiora attivamente le prestazioni (da 0.570 a 0.479). Questo evidenzia una dinamica fondamentale della Quantum Error Correction in regime NISQ: i gate CNOT aggiuntivi necessari per l'entanglement dei qubit ancillari introducono rumore aggiuntivo nel sistema, che nel modello di depolarizzazione adottato supera i benefici del voto di maggioranza. Perché un codice correttore come il Repetition Code porti

un vantaggio netto, è necessario che il tasso di errore fisico per gate scenda al di sotto di una soglia critica di *fault-tolerance*, condizione non soddisfatta dall'hardware NISQ attuale.

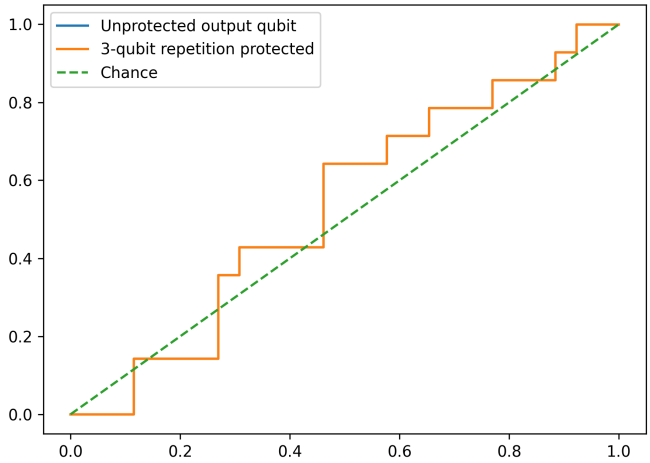

Figura 7.4: Confronto ROC tra il circuito con output non protetto e l'implementazione del Repetition Code. Le due curve principali (Unprotected e Repetition Protected) risultano pressoché sovrapposte sul modello Prototype (AUC = 0.533 in entrambi i casi). La terza voce in legenda è la linea diagonale di riferimento casuale (Chance), che appare come linea tratteggiata separata.

7.6 Discussione Complessiva delle Evidenze

La Tabella 7.6 riassume l'intera sperimentazione in un confronto sistematico. Emergono tre considerazioni principali. Primo, il Quantum Kernel SVM si conferma l'approccio più affidabile in condizioni ideali, grazie alla stabilità geometrica della separazione nello spazio di Hilbert. Secondo, il risultato di Ham VQC a $t = 0.1$ con rumore (0.768) dimostra che in alcune configurazioni il rumore NISQ può essere una risorsa piuttosto che un ostacolo. Terzo, il divario residuo rispetto alla baseline classica (0.833) riflette i limiti tecnologici dell'era NISQ: circuiti profondi degradano per decoerenza, la correzione attiva dell'errore richiede tassi di rumore ancora irraggiungibili, e la scalabilità oltre le poche decine di qubit rimane un problema aperto. L'evoluzione del-

l'hardware quantistico nei prossimi anni rappresenta il fattore determinante per superare questo divario.

Modello	**Condizione**	**ROC AUC**	**Note**
Regressione Logistica	baseline classica	0.833	riferimento
Quantum Kernel SVM	CV, no rumore	0.730 $\pm$0.025	più stabile
Ham VQC ($t = 0.5$)	CV, no rumore	0.549 $\pm$0.053	
Ham VQC ($t = 0.1$)	no rumore	0.481	barren plateau
VQC Prototype	CV, no rumore	0.585 $\pm$0.081	alta varianza
Ham VQC ($t = 0.1$)	con rumore NISQ	**0.768**	best quantistico
Ham VQC ($t = 0.5$)	con rumore NISQ	0.661	
Ham VQC ($t = 1.0$)	con rumore NISQ	0.621	
VQC Prototype	con rumore NISQ	$\sim$0.51	piatto, barren plateau
ZNE Mitigated	Prototype con rumore	0.572	+0.002 su noisy
Ham (test set)	full eval, con rumore	0.402	overfitting grave
Repetition Code	Prototype	0.533	neutro

Tabella 7.4: Riepilogo completo delle prestazioni di tutti i modelli testati. La baseline classica è la Regressione Logistica. I modelli sono raggruppati per condizione sperimentale: no rumore (CV), con rumore, mitigazione e valutazione completa.

Capitolo 8

Conclusioni

8.1 Sintesi dei Risultati

Il presente lavoro ha esplorato le potenzialità del Quantum Machine Learning nella diagnostica del diabete, affrontando sistematicamente le sfide imposte dall'era NISQ. Partendo dall'analisi del dataset Pima Indians Diabetes, si sono progettati e valutati tre architetture quantistiche: Quantum Kernel SVM, VQC Hamiltoniano e VQC Prototype, confrontandole con una baseline classica di Regressione Logistica (AUC = 0.833).

Lo studio progressivo su architetture a 4, 6 e 8 qubit ha confermato che uno spazio di Hilbert sufficientemente ampio è fondamentale per catturare la complessità delle feature cliniche. Tra i modelli testati in ambiente ideale, il Quantum Kernel SVM ha mostrato le prestazioni migliori e più stabili (AUC = 0.730, std ± 0.025 in cross-validation). Il VQC Prototype ha invece evidenziato il fenomeno dei Barren Plateaus in modo empiricamente documentato: la curva di training rimane piatta per 120 epoche, con gradiente sostanzialmente nullo, confermando le previsioni teoriche con dati sperimentali propri.

Il risultato più significativo e originale riguarda l'effetto del parametro di evoluzione hamiltoniana t. L'introduzione del rumore hardware a $t = 0.1$, anziché degradare le prestazioni, ha prodotto un aumento della ROC AUC da 0.481 (no rumore, barren plateau) a **0.768** (con rumore), il miglior risultato quantistico dell'intera sperimentazione. Questo effetto di *noise-assisted learning* dimostra che in determinate condizioni architetturali l'hardware NISQ può essere sfruttato come risorsa, non solo subito come limite.

Sul fronte delle strategie di tolleranza al rumore, la Zero-Noise Extrapolation (ZNE) ha mostrato un recupero parziale dell'accuratezza (dal 37.5% al 39.58%) senza modificare il circuito, rivelandosi l'approccio più maturo tra

quelli testati. Il Repetition Code a 14 qubit, al contrario, non ha prodotto vantaggi netti: sul modello Prototype le prestazioni sono rimaste invariate, mentre sul modello HamVQC ha introdotto un peggioramento attivo (da AUC 0.570 a 0.479), a causa dell'overhead di rumore introdotto dai gate CNOT ancillari.

8.2 Difficoltà Emerse e Problemi Irrisolti

Il lavoro ha incontrato alcune difficoltà strutturali che è utile documentare per chi intendesse proseguire questa ricerca.

Overfitting nei modelli hamiltoniani. L'analisi train/val/test del modello HamVQC ha rivelato un divario grave tra training AUC (0.781) e test AUC (0.402). Questo non è imputabile solo al rumore hardware, ma a un problema di generalizzazione: il modello ha memorizzato il training set senza apprendere pattern realmente trasferibili. La piccola dimensione del dataset PIMA (768 campioni) amplifica questo rischio nei modelli con molti parametri variazionali.

Limite della soglia di fault-tolerance. La Quantum Error Correction ha dimostrato empiricamente che in regime NISQ non porta benefici netti. Il tasso di errore fisico per gate degli hardware attuali supera la soglia critica necessaria affinché la ridondanza logica compensi il rumore aggiuntivo introdotto dai gate ancillari. Questo è un limite tecnologico fondamentale, non algoritmico.

Metriche avanzate non implementate. Le metriche di analisi quantistica avanzata descritte nella metodologia (Kernel Target Alignment, misura di Meyer-Wallach, dimensione effettiva) non sono state calcolate nella sperimentazione finale. Rappresentano quindi un'analisi aggiuntiva da completare per caratterizzare pienamente la qualità dell'apprendimento quantistico.

Gap preprocessing classico/vantaggio quantistico. Come evidenziato nel Capitolo 5, rimane aperta la questione se il vantaggio osservato nei modelli ibridi derivi dall'architettura quantistica o dalla fase di preprocessing classico (PCA, normalizzazione). Un esperimento controllato che variasse sistematicamente il preprocessing mantenendo fisso il modello quantistico sarebbe necessario per rispondere a questa domanda.

8.3 Prospettive Future

I risultati ottenuti suggeriscono diverse direzioni prioritarie per chi volesse estendere questo lavoro.

Esecuzione su QPU fisiche. L'intera sperimentazione si è svolta su simulatori. Il passaggio a Quantum Processing Unit reali permetterebbe di confrontare il rumore simulato con quello reale, colmando uno dei gap principali identificati in letteratura. Anche un singolo esperimento comparativo a basso numero di qubit avrebbe valore scientifico significativo.

Sistematica dell'effetto t. L'effetto del parametro di evoluzione hamiltoniana merita uno studio più approfondito. Una griglia di valori di t più fitta (ad esempio $t \in \{0.05, 0.1, 0.2, 0.5, 1.0, 2.0\}$) permetterebbe di caratterizzare con precisione la relazione tra tempo di evoluzione, entanglement prodotto, e interazione con il rumore hardware. Si potrebbe anche collegare questo parametro alle metriche di entanglement (Meyer-Wallach) per verificare se l'effetto di *noise-assisted learning* è correlato all'entanglement generato.

Implementazione del QRC. Il paradigma del Quantum Reservoir Computing, introdotto nella metodologia ma non implementato nella sperimentazione finale, rappresenta la direzione più promettente per evitare i Barren Plateaus. L'eliminazione dell'ottimizzazione dei gate interni, sostituita da un semplice readout lineare classico, potrebbe risolvere strutturalmente il problema di convergenza osservato nel VQC Prototype.

Verso la fault-tolerance. L'implementazione di codici correttori più sofisticati (Surface Code, Steane Code) su hardware con tassi di errore inferiori alla soglia critica, attesi nell'arco del prossimo decennio con l'evoluzione verso qubit logici fault-tolerant, renderà la QEC effettivamente vantaggiosa. Monitorare l'evoluzione dell'hardware e ripetere i benchmark di questo lavoro su architetture più avanzate sarebbe un contributo naturale di follow-up.

Interpretabilità clinica. Nessuno dei modelli quantistici testati offre al medico una spiegazione del processo decisionale. Integrare tecniche di explainability (quantum SHAP, analisi delle traiettorie nello spazio di Hilbert) in modelli QML per la diagnostica è un gap aperto che combina rilevanza clinica e ricerca fondamentale.

Bibliografia

[1] EG Acuña Acuña. «Quantum-assisted early detection of diabetic retinopathy: A novel integration of quantum machine learning in biomedical imaging». In: *Med Data Min* 8.3 (2025), p. 18.

[2] Sevdanur GenÇ. «Performance analysis of quantum and classical machine learning models for feature selection and classification of the diabetes health indicators dataset». In: *2024 8th International Artificial Intelligence and Data Processing Symposium (IDAP)*. IEEE. 2024, pp. 1–7.

[3] Juan Kenyhy Hancco-Quispe, Jordan Piero Borda-Colque e Fred Torres-Cruz. «Quantum machine learning applied to the classification of diabetes». In: *arXiv preprint arXiv:2301.00109* (2022).

[4] Wajiha Rahim Khan et al. «Diabetes prediction using an optimized variational quantum classifier». In: *International Journal of Intelligent Systems* 2025.1 (2025), p. 1351522.

[5] Danyal Maheshwari, Begona Garcia-Zapirain e Daniel Sierra-Soso. «Machine learning applied to diabetes dataset using Quantum versus Classical computation». In: *2020 IEEE international symposium on signal processing and information technology (ISSPIT)*. IEEE. 2020, pp. 1–6.

[6] BBNS Prakash et al. «Comparative performance analysis of quantum algorithm with machine learning algorithms on diabetes mellitus». In: *2023 International Conference on Intelligent and Innovative Technologies in Computing, Electrical and Electronics (IITCEE)*. IEEE. 2023, pp. 1178–1183.

[7] Daniel Sierra-Sosa et al. «Diabetes Type 2: Poincaré Data Preprocessing for Quantum Machine Learning.» In: *Computers, Materials & Continua* 67.2 (2021).

[8] Antonio Tudisco, Deborah Volpe e Giovanna Turvani. «Quantum Machine Learning in Healthcare: Evaluating QNN and QSVM Models». In: *arXiv preprint arXiv:2505.20804* (2025).

[9] Dixit Vimal. «PIMA Diabetes Prediction Using Machine Learning and Quantum Machine Learning Techniques». In: *2024 ITU Kaleidoscope: Innovation and Digital Transformation for a Sustainable World (ITU K)*. 2024, pp. 1–7. DOI: 10.23919/ITUK62727.2024.10772814.

[10] Yu Zhu et al. «Secretary bird optimization algorithm based on quantum computing and multiple strategies improvement for KELM diabetes classification». In: *Scientific Reports* 15.1 (2025), p. 3774.